

Guide RAG / BrainVault pour débutant — comprendre et surveiller la partie IA de Riemann_Lab

Fichier : Guide-RAG-BrainVault-Debutant.md · Dossier : wiki (racine)

Branche : master (wiki) · Auteur : hprzeta · MAJ : 2026-07-19

■ **Rôle de cette page.** Expliquer **sans jargon** comment fonctionne le cerveau IA du projet (le RAG « BrainVault » sur le SSD /mnt/vault_rag), ce que sont tous ces fichiers mystérieux (chroma.sqlite3, data_level0.bin, docstore.json...), et comment **surveiller** le système quand il tourne avec le script rag_monitor.py. Tous les exemples sont **réels** : ce sont les tests effectués les 4-5 juillet 2026 sur PC1.

1. C'est quoi un RAG ? (l'image du bibliothécaire)

RAG = *Retrieval-Augmented Generation* — « génération augmentée par récupération ».

Imagine un bibliothécaire (le modèle IA, ex. **mathstral**) très intelligent mais qui n'a **jamais lu tes documents**. Si tu lui demandes « quel est le seuil SEUIL_1NEWTON ? », il ne peut pas le savoir : cette valeur n'existe que dans TES fichiers (wiki, analyses, code).

Le RAG résout ça en 2 temps :

Retrieval (récupération) : avant de répondre, le système **cherche dans ta bibliothèque** les 3-5 passages les plus pertinents pour la question.

Generation (génération) : il donne ces passages au modèle IA avec la consigne « réponds à la question EN T'APPUYANT sur ces extraits ».

Résultat : le modèle répond avec **tes données**, à jour, et peut **citer ses sources**.

Sans RAG, il inventerait (« hallucination »). Avec RAG, il consulte.

[*] C'est exactement pour ça qu'on a corrigé les IP .94->.52 et posé les bandeaux ARCHIVE avant l'ingestion : **le RAG croit ce qu'on lui donne**. Documents faux = réponses fausses.


2. Le vocabulaire IA — traduit en français simple

Terme	Traduction simple	Dans Riemann_Lab
LLM	Le « cerveau » : un modèle de langage qui lit et écrit du texte	mathstral (spécialisé maths), deepseek-coder, qwen3 via Ollama
Ollama	Le logiciel qui fait tourner les LLM en local sur ton PC (pas de cloud)	modèles stockés sur /mnt/data/models_ia/ollama/


Terme	Traduction simple	Dans Riemann_Lab
Chunk	Un morceau de document (~quelques paragraphes). On découpe car le LLM ne peut pas tout lire d'un coup	106 documents -> 838 chunks
Embedding	La traduction d'un texte en nombres : une liste de 384 nombres qui capture le <i>sens</i> du texte	modèle all-MiniLM-L6-v2
Vecteur	Cette liste de nombres, vue comme une flèche dans un espace à 384 dimensions . Deux textes de sens proche -> flèches qui pointent presque dans la même direction	1 chunk = 1 vecteur de 384 nombres
Similarité	La mesure « ces deux flèches pointent-elles dans la même direction ? » (angle entre vecteurs). C'est ça, la recherche sémantique : par le SENS, pas par les mots exacts	« seuil Newton » retrouve « SEUIL_1NEWTON=20000 » même sans mot commun
Base vectorielle	La base de données qui stocke tous les vecteurs et sait trouver les plus proches très vite	ChromaDB dans /mnt/vault_rag/chromadb/
Collection	Un « rayon » de la base vectorielle (un ensemble de chunks)	riemann_lab_corpus (838 chunks)
HNSW	L'astuce qui rend la recherche instantanée : un réseau de « raccourcis » entre vecteurs voisins, comme un GPS qui évite de tester toutes les routes	fichier link_lists.bin
LlamaIndex	Le chef d'orchestre : lit les documents, découpe en chunks, appelle l'embedding, remplit ChromaDB, puis pilote les requêtes	installé dans zeta_env (core 0.14.23)
Ingestion	L'opération « remplir la bibliothèque » : documents -> chunks -> vecteurs -> ChromaDB	log : agent_logs/ingestion_20260705_140201.log
Corpus	L'ensemble des documents sources ingérés	wiki + code src/ + prompts ARCHIVE
Requête RAG	Question -> embedding de la question -> recherche des chunks proches -> réponse du LLM avec ces chunks	test SEUIL_1NEWTON [OK]

3. Le schéma complet — de tes documents à la réponse

Phase A — Ingestion (faite le 05/07/2026, ~5 min)



Phase B — Requête (chaque question posée au RAG)



[t] Ordres de grandeur sur PC1 : la recherche vectorielle (②) est quasi instantanée ;
c'est la génération mathstral (④) qui prend du temps (modèle 7B sur CPU, 1-3 min/réponse).

4. Les fichiers du SSD — rôle de chacun

Ce qu'on voit dans /mnt/vault_rag/ après l'ingestion :

Fichier / dossier	Rôle	Analogie
chromadb/chroma.sqlite3	Métastore : le texte des chunks, leurs métadonnées (fichier source, date), la liste des collections	Le catalogue de la bibliothèque
chromadb//data_level0.bin	Les vecteurs eux-mêmes (838 × 384 nombres)	Les fiches de sens de chaque passage
chromadb//link_lists.bin	Le graphe HNSW : les raccourcis entre vecteurs voisins	Le plan des rayons pour trouver vite
chromadb//header.bin, length.bin	Paramètres de l'index, tailles des entrées	Étiquettes techniques
llamaindex_cache/docstore.json	Les chunks avec leur texte et provenance, côté LlamaIndex	Photocopies des passages
llamaindex_cache/index_store.json	Structure de l'index (quel chunk -> quel index)	Sommaire
llamaindex_cache/graph_store.json, image__vector_store.json	Relations entre docs / images — quasi vides (corpus texte)	—
corpus/	Prévu pour des copies locales de sources ; vide car l'ingestion lit les sources en place (wiki local, src/)	Rayon réservé
agent_logs/ingestion_*.log	Journal d'ingestion : docs lus, chunks créés, erreurs	Registre des entrées
lost+found/	Système ext4 (réservé root) — à ignorer	—

[!] **Un dossier = une collection.** S'il y en a deux, l'un peut être un résidu du

test hello-world (collection supprimée mais dossier restant) — vérifiable avec `rag_monitor.py`.

5. Les tests réels — ce qui a été validé

Test 1 — « Hello world » ChromaDB (05/07, étape 2 du plan)

Le test minimal qui prouve que la chaîne fonctionne :

Création d'une collection de test dans `/mnt/vault_rag/chromadb/`

Insertion d'1 document -> embedding automatique (all-MiniLM-L6-v2, téléchargé dans `~/ .cache/chroma`)

Requête sémantique : la question retrouve le document [OK]

Suppression propre de la collection

Résultat : écriture/lecture/suppression validées **sur le SSD** ; `chroma.sqlite3` (188 Ko) créé.

Test 2 — Ingestion complète (05/07, étape 3)

Indicateur	Valeur
Documents sources	106 (59 wiki + 44 code + 3 prompts ARCHIVE)
Chunks créés	838
Collection	<code>riemann_lab_corpus</code>
Exclusions respectées	<code>Handoff.md</code> , <code>*.bak</code> , logs
Durée	~5 min 32 s
Script réutilisable	<code>scripts/rag_ingest_corpus.py</code> (commit 61ca640)

Test 3 — Première requête RAG (05/07, étape 4)

Question : « *Quel est le seuil SEUIL_1NEWTON et pourquoi cette valeur ?* »

-> Le retrieval retrouve le **bon extrait** dans `analyse_problemes_v13_v15.md` [OK]

C'est la preuve que la recherche **sémantique** marche : le système comprend que la question parle du seuil adaptatif de la Phase 2 Illinois, sans correspondance mot-à-mot exigée.

■ **Test de contrôle qualité recommandé** : demander « Quelles sont les IP des 4 machines

du cluster ? ». Réponse attendue : `.24 / .52 / .22 / .54`. Si `.94` sort -> une archive

non taguée a fui dans le corpus (voir règle d'ingestion dans `[etat_rag_brainvault_20260704]`).

6. Surveiller le RAG — quoi observer et pourquoi

Quand le RAG « tourne » (ingestion en cours, ou requêtes), voici les **points de mesure** qui disent si tout va bien :

7. Le problème du K et du retrieval imparfait

Section ajoutée après diagnostic du 19/07/2026.

C'est quoi K ?

Quand tu poses une question, ChromaDB retourne les **K chunks les plus proches** (K = nombre fixé à l'avance, ex. K=6). Seuls ces K chunks sont donnés à mathstral pour générer la réponse.

Question posée



ChromaDB calcule la distance entre la question et les 838 chunks



Tri par distance croissante :

Rang 1	distance	1.116	→ chunk	quelconque	← donné à mathstral	■
Rang 2	distance	1.134	→ chunk	quelconque	← donné à mathstral	■
Rang 3	distance	1.151	→ chunk	quelconque	← donné à mathstral	■
Rang 4	distance	1.163	→ chunk	quelconque	← donné à mathstral	■
Rang 5	distance	1.171	→ chunk	quelconque	← donné à mathstral	■
Rang 6	distance	1.179	→ chunk	quelconque	← donné à mathstral	■

[illegible]

Rang 7 distance 1.182 → BON chunk ■ jamais vu par mathstral !!!

Le bon chunk existe dans la base — mais il n'est pas dans le top-K.

Mathstral ne peut pas lire ce qu'on ne lui donne pas.

Pourquoi all-MiniLM-L6-v2 discrimine mal ?

Ce modèle d'embedding a été entraîné sur du **texte anglais généraliste**.

Il ne comprend pas bien :

- Le français technique ("seuil adaptatif de la phase Newton")
- Le code mélangé au texte (SEUIL_1NEWTON=20000 dans un .c)
- Les notations mathématiques (Z_{rs} , $\zeta(s)$, $T=100k$)

Résultat : les distances de **tout le corpus** se retrouvent entassées entre 1.1 et 1.2

- le modèle ne fait plus la différence entre un chunk pertinent et du bruit.

Solutions possibles

Solution	Difficulté	Effet
Augmenter K (ex. 6->15)	Facile, 1 ligne	Le bon chunk entre dans le top-K, mais plus de bruit pour mathstral
Changer de modèle d'embedding	Moyen	Meilleure discrimination, mais ré-ingestion complète obligatoire
Améliorer le chunking (garder code + contexte ensemble)	Long	Chunks plus riches sémantiquement

[!] Changer le modèle d'embedding = tout refaire : les 838 vecteurs actuels deviennent

inutiles car calculés avec l'ancien modèle. Les deux modèles parlent des "langues de

nombres" incompatibles.

8. Le problème de l'hallucination — session du 19/07/2026

Ce qui a été découvert lors du premier test génératif complet avec mathstral.

Les 2 questions de validation

Q1 — "Quelle est la valeur de SEUIL_1NEWTON ?"

Réponse attendue : 20000

Résultat : [OK] correct — par chance (chunk voisin illinois_arb.c dans le top-K)

Q2 — "Quelles sont les IP des 4 machines du cluster ?"

Réponse attendue : .24 / .52 / .22 / .54

Résultat : [KO] **mathstral invente 2 IP sur 4** (.53 / .25 au lieu de .52 / .22)

Pourtant le retrieval de Q2 était **bon** (distances 0.99–1.12, les bons chunks étaient là).

Leçon clé : un bon retrieval ne garantit pas une génération fidèle sur des données factuelles précises. Mathstral "lit" correctement les chunks mais **invente quand même**.

Tentative échouée : forcer la citation des sources

Idée : ajouter dans le prompt "cite le fichier source après chaque fait".

Résultat : **PIRE** — retest Q2 -> **4/4 IP fausses** (contre 2/4 sans consigne),

avec citations correctes des fichiers sur chaque ligne. La citation d'une source réelle n'empêche pas l'invention de la valeur. Un modèle 7B local ne peut pas s'auto-vérifier.

Exemple de réponse avec consigne de citation :

PC1 :	[Architecture-Cluster-Zeta.md]	← IP fausse, fichier réel
PC2 :	[Architecture-Cluster-Zeta.md]	← IP fausse, fichier réel
PC3 :	[Architecture-Cluster-Zeta.md]	← IP fausse, fichier réel
PC4 :	[Architecture-Cluster-Zeta.md]	← IP fausse, fichier réel

Solution retenue : vérification programmatique

Fonction valeurs_non_ancrees() ajoutée dans scripts/rag_query.py (commit 01934df) :

```
# Principe : comparer chaque nombre/IP de la réponse
# au texte BRUT des chunks récupérés
# → si une valeur est dans la réponse mais absente des chunks → signalée

valeurs_non_ancrees(reponse, chunks_recus)
# ■ détecte 2/2 IP fausses (sans consigne de citation)
# ■ détecte 3/3 IP fausses (avec consigne de citation)
```

Limite connue : ne détecte pas une valeur correcte attribuée à la mauvaise entité

(le chiffre .52 existe dans les chunks, mais ce n'est pas l'IP de PC3).

Bugs de détection corrigés

Deux faux positifs trouvés et corrigés dans la même session :

Bug	Symptôme	Fix
Comparaison chemin complet vs basename	illinois_arb.c ≠ src/.../illinois_arb.c -> fausse alerte	os.path.basename() des deux côtés
Séparateurs de milliers	mathstral répond 20,000.0 pour 20000.0 -> fausse alerte	normaliser_separateurs_milliers()

[*] Instabilité mathstral documentée : la même valeur numérique peut sortir sous 3 formats différents selon les appels (20000.0 -> 20,000.0 -> 20.000). À garder en tête pour tout test de validation RAG.

9. État du chantier RAG — bilan au 19/07/2026

Étape	État	Date
1. Corpus poussé sur inbox-ia + manifeste	[OK]	05/07
2. Stack installée + hello-world SSD	[OK]	05/07
3. Ingestion complète (106 docs -> 838 chunks)	[OK]	05/07
4. Première requête RAG retrieval (SEUIL_1NEWTON)	[OK]	05/07
5. Script rag_query.py industrialisé (retrieval + génération)	[OK]	19/07 (86ab0ae)
6. Test génératif complet Q1+Q2 avec mathstral	[OK]	19/07
7. Garde-fou anti-hallucination valeurs_non_ancrees()	[OK]	19/07 (01934df)
8. Fix faux positifs (basename + séparateurs milliers)	[OK]	19/07 (3307bad)
9. Améliorer le retrieval (K, modèle embedding, chunking)	[>]	—
10. Parcours Skilljar (API -> MCP -> Subagents -> Agent Skills)	[>]	—

Chantier RAG 3 blocs considéré clos. La base est industrialisée et durcie.

Prochaine décision : améliorer le retrieval (§7) ou passer au parcours Skilljar.

Voir aussi

- [etat_rag_brainvault_20260704] — le bilan d'audit et le plan en 5 étapes
- [Guide-Ollama-Pratique] — config matérielle, incidents OOM, benchmarks

- *[ORGANISATION_FICHIERS]* — où vit quoi (règle d'ingestion, inbox-ia)
- *[STACK]* — outils, matériel, roadmap Objectif 2
- *[Bonnes-Pratiques-Claude-Code]* — gestion contexte/tokens
- `scripts/rag_query.py` — script RAG industrialisé (commit 3307bad)